

Informe técnico – Trabajo teórico-práctico

Convenio PLUS TI – Universidad del Valle 2026

Andre Marroquín – Carné: 22266

Gabriel Paz – Carné: 221087

Mauricio Lemus – Carné: 22461

1. Resumen

El trabajo se desarrolló en dos fases. En la primera fase se trabajó con el dataset `01_bo_vip_seed22_n100000.csv`, correspondiente a transacciones sintéticas de tarjetas de crédito de un banco de Bolivia con clientela VIP. El objetivo principal fue evaluar modelos de clasificación binaria para detectar fraude, dando especial importancia a la reducción de falsos positivos entre las alertas generadas. La métrica principal usada para comparar estrategias fue:

$$ratio\ de\ falsos\ positivos = \frac{FP}{TP + FP}$$

Esta métrica mide qué proporción de las alertas marcadas como fraude son realmente falsas alarmas. Esto es importante en fraude porque un modelo puede tener buen recall y parecer adecuado en las métricas generales, pero resultar poco útil en la operación si genera demasiadas alertas incorrectas.

En la segunda fase se trabajó con tres bancos. Banco 1 y Banco 2 tenían etiqueta real `is_fraud` y se utilizaron para entrenamiento, validación y comparación de estrategias. Banco 3 era el conjunto objetivo que había que predecir, por lo que se trató como no etiquetado y se utilizó para generar las inferencias. A partir de Banco 1 y Banco 2 se entrenaron modelos locales por banco, se construyeron ensambles federados simulados y se compararon contra modelos centralizados. Además, las correcciones recibidas sobre el primer 30 % de Banco 3 se usaron para seleccionar la metodología final aplicada al 100 % del banco objetivo.

Los notebooks anexos son:

- `ObjetivoA.ipynb`: implementación completa de métricas custom con LightGBM.
- `ObjetivoB.ipynb`: entrenamiento federado simulado, comparación de estrategias e inferencia sobre Banco 3.

2. Metodología

2.1. Fase A: métricas custom para reducir falsos positivos

El dataset de Banco 1 contiene 100,003 transacciones, con 4,919 fraudes y 95,084 operaciones legítimas. La tasa global de fraude es de 4.92 %, por lo que se trata de un problema desbalanceado. Se construyó una variable proxy para identificar transacciones de app móvil o canal digital equivalente, derivada a partir de señales como canal e-commerce, terminal virtual, modo de entrada POS y condición de comercio electrónico.

El segmento mobile/app quedó compuesto por 46,312 transacciones, con una tasa de fraude de 8.02 %. El resto del dataset tuvo una tasa de 2.24 %. Esta diferencia justificó evaluar el desempeño global y también el comportamiento específico del modelo en el segmento digital.

La separación se manejó de la siguiente manera: entrenamiento con enero–mayo de 2025 y evaluación con junio de 2025. El conjunto de entrenamiento quedó con 83,817 filas y el de prueba con 16,186 filas.

La ingeniería de variables incluyó indicadores temporales, comportamiento por cliente, contadores recientes y desviaciones de monto:

- `time_since_last_txn_min`, `txn_count_last_1h`, `txn_count_last_24h`
- `amount_zscore_customer`, `amount_ratio_customer_mean`, `amount_ratio_customer_median`
- Contadores históricos por cliente, tarjeta y comercio
- Variables de canal digital, horario nocturno, fin de semana y transacción internacional

Se entrenó un modelo base LightGBM con métricas tradicionales y tres variantes con funciones `feval` personalizadas:

Métrica custom	Intención
mobile_app_false_positive_ratio	Minimizar directamente la proporción de falsos positivos en el segmento mobile/app.
mobile_app_recall_constrained_fp_ratio	Reducir falsos positivos penalizando si el recall cae por debajo de 90 %.
mobile_app_alert_quality	Combinar recall, proporción de falsos positivos y volumen de alertas para buscar alertas más útiles.

El criterio principal de comparación fue alcanzar aproximadamente 90 % de detección y, bajo esa restricción, seleccionar la estrategia con menor $FP / (TP + FP)$.

2.2. Fase B: entrenamiento federado simulado e inferencia sobre Banco 3

Para la segunda fase se cargaron tres datasets correspondientes a bancos de distintos países y segmentos:

Banco	País	Segmento
Banco 1	Bolivia	VIP
Banco 2	Brasil	Privado
Banco 3	Guatemala	Estatat

Solo Banco 1 y Banco 2 contaban con etiqueta válida. Banco 3 se utilizó para generar la predicción final de fraude.

La ingeniería de variables fue la misma para los tres bancos e incluyó: transformaciones numéricas (`log_amount`, ratio respecto al baseline del cliente), indicadores temporales (hora, día, mes, transacción nocturna, horario hábil), proxies de canal digital (e-commerce, entrada manual, contactless), y contadores/acumuladores por cliente, tarjeta y comercio (conteo de transacciones, monto total, monto promedio, ratio monto/promedio, conteo de comercios únicos).

Para controlar la fuga de información se excluyeron identificadores directos de banco, cliente, tarjeta, comercio y terminal; columnas de país, ciudad y moneda local; y columnas con más del 95 % de nulos o cardinalidad excesiva. Esto lo que hizo fue obligar al modelo a aprender patrones transaccionales generalizables y no memorizar la información específica de cada institución.

Las estrategias entrenadas y comparadas fueron:

Estrategia	Descripción
Modelo local Banco 1	ExtraTrees entrenado exclusivamente con datos de Banco 1.
Modelo local Banco 2	ExtraTrees entrenado exclusivamente con datos de Banco 2.
Ensamble federado (pesos iguales)	Promedio simple de probabilidades de los modelos locales.
Ensamble federado (pesos por desempeño)	Promedio ponderado por F1 en validación de cada modelo local.
Centralizado baseline (ExtraTrees)	Modelo entrenado con datos combinados de Banco 1 y Banco 2.
Centralizado logístico	Regresión logística sobre datos combinados.
Centralizado boosting	HistGradientBoosting sobre datos combinados.
Boosting con hiperparámetros tuneados	HistGradientBoosting optimizado con GridSearchCV y validación cruzada.

La búsqueda de hiperparámetros exploró combinaciones de `max_iter`, `learning_rate`, `max_leaf_nodes` y `l2_regularization` mediante `GridSearchCV` con validación cruzada estratificada. El mejor estimador se reentrenó con todos los datos disponibles antes de competir en la selección final.

Primero se realizó una selección interna usando Banco 1 y Banco 2 mediante puntuaciones compuestas que combinaban F1 promedio entre bancos, F1 mínimo entre bancos, ROC AUC, recall y penalización por false positive ratio. Esta selección permitió identificar el mejor modelo bajo validación interna.

Después, las correcciones recibidas sobre el primer 30 % de Banco 3 se utilizaron como criterio específico del banco objetivo. La metodología con mejor desempeño corregido en ese subconjunto fue la usada para generar la inferencia final sobre el 100 % de Banco 3.

3. Descripción de la implementación práctica

La Fase A está hecha en `ObjetivoA.ipynb`. El notebook normaliza nombres de columnas, valida el target, detecta columnas relevantes del estándar ISO 8583, construye la fecha transaccional desde `de7_transmission_datetime`, separa enero–mayo contra junio, crea variables predictivas y entrena LightGBM. La evaluación se hizo con umbral fijo 0.50 y con un umbral elegido automáticamente para alcanzar recall cercano a 90 %, que fue el punto principal de comparación.

La Fase B está hecha en `ObjetivoB.ipynb`. El notebook carga los tres bancos, genera variables equivalentes, excluye columnas con riesgo de fuga y entrena las estrategias locales, federadas simuladas y centralizadas. Los modelos se guardaron en `outputs_fase_B/04_models`, los reportes en `outputs_fase_B/07_reports` y las inferencias en `outputs_fase_B/05_predictions`.

4. Análisis de resultados

4.1. Fase A

El modelo seleccionado como final fue el baseline LightGBM con métricas tradicionales. Al buscar el umbral que garantiza recall cercano a 90 % en el segmento mobile/app, el baseline presentó el menor ratio de falsos positivos de las estrategias evaluadas.

Estrategia	Recall	Prec.	FP	TP	Ratio FP
Baseline LightGBM	95.31 %	14.34 %	3,034	508	85.66 %
mobile_app_alert_quality	95.31 %	12.81 %	3,458	508	87.19 %
mobile_app_recall_constrained_fp_ratio	95.50 %	12.68 %	3,506	509	87.32 %
Modelo tuneado custom	95.50 %	11.78 %	3,813	509	88.22 %
mobile_app_false_positive_ratio	100.00 %	7.21 %	6,864	533	92.79 %

Las métricas custom mejoraron el ordenamiento del modelo. Por ejemplo, `mobile_app_recall_constrained_fp_ratio` alcanzó AUC PR de 0.885 en mobile/app frente a 0.771 del baseline. Sin embargo, al forzar una detección cerca a 90 %, ese mejor ranking no se convirtió en menor proporción de falsos positivos. Con umbral fijo 0.50 sí aparecieron alertas más limpias. La métrica `mobile_app_recall_constrained_fp_ratio` logró 82.36 % de recall, 93.40 % de precisión y 6.60 % de ratio FP en mobile/app, pero no alcanzó el recall establecido anteriormente para la comparación principal.

4.2. Fase B

Los modelos locales de Banco 1 y Banco 2 se usaron como base para los ensambles federados simulados. Para la selección interna se compararon seis estrategias candidatas sobre los conjuntos de validación de Banco 1 y Banco 2. La estrategia final se eligió con una puntuación compuesta que pondera F1 promedio, F1 mínimo entre bancos, ROC AUC, recall y penaliza el ratio de falsos positivos.

Estrategia	Umbral	F1 prom.	F1 mín.	ROC AUC	Recall	Ratio FP
HistGradientBoosting central	0.85	0.801	0.796	0.878	0.687	0.041
HistGradientBoosting tuneado	0.85	0.794	0.784	0.880	0.674	0.033
ExtraTrees centralizado	0.80	0.676	0.623	0.872	0.603	0.223
Regresión logística central	0.90	0.592	0.572	0.867	0.456	0.157
Federado ponderado	0.65	0.556	0.409	0.864	0.523	0.406
Federado pesos iguales	0.60	0.544	0.393	0.863	0.556	0.467

En validación interna con Banco 1 y Banco 2, la mejor estrategia fue `central_hist_gradient_boosting_model` con umbral 0.85. Los ensambles federados simulados permitieron comparar transferencia entre bancos, pero no superaron al mejor modelo centralizado bajo esta validación interna. Sin embargo, esta selección se revisó posteriormente con las correcciones recibidas sobre el primer 30 % de Banco 3.

Modelo	Accuracy	Prec.	Recall	F1	Ratio FP
Baseline centralizado	97.20 %	98.44 %	34.62 %	51.22 %	1.56 %
Federado pesos iguales	97.84 %	91.84 %	53.92 %	67.95 %	8.16 %
Federado ponderado (Sin correcciones de PlusTi)	–	–	–	–	–

El modelo federado con pesos iguales obtuvo el mejor F1, recall y accuracy sobre las correcciones recibidas del primer 30 % de Banco 3. El modelo federado ponderado no pudo compararse en esta etapa porque no se recibió corrección para esa entrega preliminar.

Las inferencias sobre el primer 30 % de Banco 3 se generaron con tres estrategias (baseline centralizado, ensamble con pesos iguales y ensamble ponderado) y quedan en `outputs_fase_B/05_predictions`. Para la inferencia final sobre el 100 % de Banco 3 se usó `federated_equal_weight_model` con umbral 0.60, al ser la mejor metodología según las correcciones recibidas del primer 30 %. El modelo predijo 1,778 fraudes sobre 100,000 transacciones, equivalente a una tasa esperada de 1.78 %.

5. Dataset 3 con inferencia realizada

La inferencia final para Banco 3 quedó guardada en:

```
outputs_fase_B/05_predictions/bank_3_full_final_inference.xlsx
```

La inferencia fue generada con `federated_equal_weight_model` y umbral 0.60. Esta elección se basó en las correcciones recibidas sobre el primer 30 % de Banco 3, no únicamente en la validación interna con Banco 1 y Banco 2.

El archivo contiene una única columna llamada `is_fraud`, con valores `True` o `False`, y mantiene las 100,000 transacciones en el orden de entrada. También se generó el archivo de auditoría:

```
outputs_fase_B/05_predictions/bank_3_full_final_inference_audit.csv
```

Ese archivo de auditoría no es el final, pero permite revisar la probabilidad asignada, el umbral utilizado y la estrategia que generó cada predicción.

6. Conclusiones

El trabajo permitió ver dos enfoques para la detección de fraude transaccional. En la Fase A se evidenció que el uso de funciones `feval` personalizadas en LightGBM permite ajustar el comportamiento del modelo hacia criterios operativos específicos, aunque su efecto depende del régimen de umbral bajo el cual se evalúe el modelo. La división temporal del conjunto de prueba permitió realizar una evaluación más realista y evitar fuga de información.

En la Fase B se trabajó con una simulación de aprendizaje federado para representar un escenario con varios bancos, sin necesidad de reunir todos los datos originales en un solo lugar. Los ensambles federados ayudaron a comparar distintas estrategias y a no depender únicamente de la información de un banco. En la validación interna con Banco 1 y Banco 2, el modelo centralizado HistGradientBoosting obtuvo el mejor desempeño. Sin embargo, al incorporar las correcciones recibidas sobre el primer 30 % de Banco 3, el ensamble federado con pesos iguales mostró mejor desempeño sobre el banco objetivo. Por esa razón, `federated_equal_weight_model` fue la metodología usada para generar la inferencia final de Banco 3.

Las principales limitaciones son: (1) el carácter sintético de los datasets, que puede no reflejar con exactitud la distribución de fraude real; (2) la simulación de federación en un único entorno local, sin comunicación real de parámetros entre nodos; y (3) la ausencia de etiqueta confiable para el 100 % de Banco 3, que impide evaluar completamente la calidad final de las inferencias generadas.

7. Anexos del repositorio

- Notebook Fase A: `ObjetivoA.ipynb`
- Notebook Fase B: `ObjetivoB.ipynb`
- Resultados Fase A: `outputs_fase_A/07_final_model/final_metrics.csv`
- Resumen Fase A: `outputs_fase_A/07_final_model/final_model_summary.json`
- Resultados Fase B: `outputs_fase_B/07_reports/selection_table.csv`
- Resumen esperado Banco 3: `outputs_fase_B/07_reports/expected_result_summary.json`
- Inferencia final Banco 3: `outputs_fase_B/05_predictions/bank_3_full_final_inference.xlsx`
- Validación interna en Banco 1 y Banco 2 del modelo usado para Banco 3: `outputs_fase_B/07_reports/bank_3_final_strategy_internal_metrics.csv`
- Correcciones preliminares Banco 3: `data/corregido`