






DETECCIÓN DE FRAUDE TRANSACCIONAL

con Aprendizaje Simulado



Reducción de falsos positivos
y transferencia entre bancos





CONTEXTO DEL PROBLEMA

Fraude transaccional y desafío operacional



El fraude transaccional genera pérdidas y afecta la confianza del cliente.



Muchos modelos detectan fraude, pero producen demasiadas falsas alertas.



RETO PRINCIPAL

Detectar más fraudes con menos falsos positivos.

¿POR QUÉ IMPORTA?




Pérdidas

Impacto financiero directo.




Cliente

Bloqueos y fricción innecesaria.



Operación

Más revisión manual y mayor costo.



Objetivo: Alto recall + bajo ratio de falsos positivos





OBJETIVO DEL PROYECTO

Desarrollar e identificar la mejor estrategia para **detectar fraude transaccional** minimizando falsos positivos en el canal digital.



OBJETIVOS CLAVE



1. Mantener alto nivel de detección
(Recall $\approx 90\%$)



2. Reducir el ratio de **falsos positivos** en el canal digital



3. Evaluar estrategias **federadas** simuladas entre bancos

MÉTRICA PRINCIPAL

$$\frac{FP}{TP + FP}$$

Ratio de Falsos Positivos
 $FP / (TP + FP)$

Proporción de alertas que son falsas alarmas.





Banco 1
Bolivia VIP

100,003 transacciones

Fraude: 4.92%

Entrenamiento Fase A




Banco 2
Brasil Privado

100,000 transacciones

Fraude: 3.21%

Entrenamiento Fase B



Banco 3
Guatemala Estatal


100,000 transacciones

Fraude: ¿?

Inferencia Final

DATASETS Y ENFOQUE GENERAL

Flujo del proyecto



Idea clave: Comparar estrategias y elegir la mejor opción para el Banco 3





FASE A: METODOLOGÍA

Detección de fraude en Banco 1



Canal: Mobile/app

1



Dataset

100,003 transacciones


2



**Division
temporal**

Ene - May / Jun

3



**Feature
engineering**

Variables de comportamiento

4



**Modelo y
evaluación**

LightGBM + recall 90%



Meta: menos falsas alertas en el canal digital





FASE A: RESULTADOS CLAVE

Segmento Mobile/App

recall objetivo: 90%



Comparación rápida

Recall

Ratio FP



1	Baseline LightGBM	95.31%	85.66%
2	alert_quality	95.31%	87.19%
3	recall_constrained_fp	95.31%	87.19%
4	Modelo tuneado custom	95.50%	88.22%
5	false_positive_ratio	100.00%	92.79%



Modelo ganador

Baseline LightGBM



Recall

95.31%



Precisión

14.34%



FP

3,034



Ratio FP

85.66%



Menor ratio de falsos positivos manteniendo alto recall.



Hallazgo principal: las metricas custom mejoran el ranking, pero el baseline generó menos falsas alertas cuando se exigió recall > 90%.





HALLAZGOS FASE A

¿Qué aprendimos del experimento?



Umbral 0.50

Las métricas custom ganan

Precisión




93.40%

Ratio FP



6.60%

Recall



82.36%

VS



Recall $\geq$ 90%

Baseline LightGBM gana

Recall



93.40%

FP



93.40%

Ratio FP



93.40%



No alcanza el recall objetivo



Menor ratio FP al exigir recall alto






FASE B: FEDERACIÓN SIMULADA

Modelos locales y ensamble entre bancos



Objetivo: Predecir Banco 3



Idea Clave: compartir aprendizaje, no los datos





ESTRATEGIAS EVALUADAS

Modelos comparados en Fase B



Centralizadas

Datos combinados B1 + B2

- ✓ HistGradientBoosting Central
- ✓ HistGradientBoosting Tuneado
- ✓ Regresión Logística & Extra Trees



Federadas

Modelos locales + ensamble

- ✓ Federado Ponderado
- ✓ Federado Pesos Iguales



Locales

Entrenados por banco

- ✓ Modelo Local Banco 1
- ✓ Modelo Local Banco 2



Idea Clave:

comparamos enfoques centralizados, federados y locales para elegir la mejor estrategia para Banco 3





COMPARACIÓN INTERNA

Evaluación de estrategias dentro de **Banco 1** considerando el canal mobile/app



MÉTRICAS UTILIZADAS

- Recall (detección de fraudes)
- Ratio de falsos positivos ($FP / (TP + FP)$)
- Volumen de alertas general

	★ Mejor estrategia	🛡️ Estrategia 2	🔍 Estrategia 3
🎯 Recall	90.3%	87.1%	92.0%
🔔 Ratio de falsos positivos	3.2%	2.5%	8.7%
⚠️ Volumen de alertas	1,250	980	2,450
🏆 Balance general	Óptimo	Bueno	Alto riesgo



La mejor estrategia seleccionada mantiene un **alto nivel de detección de falsos positivos** y un volumen de alertas manejable





BANCO 3: INFERENCIA FINAL

Resultado aplicado sobre el 100% del banco objetivo



Canal: Mobile/app



Estrategia elegida



Federado Pesos Iguales



Modelo final para Banco 3



Umbral: 0.60



Elegido tras las correcciones del primer 30%




100,000
Transacciones



1,778
Fraudes predichos



1.78%
Tasa predicha



0.170
Probabilidad media



Baseline Centralizado

F1: 51.22%

Recall: 34.62%

VS



Federado Pesos Iguales

F1: 67.95%

Recall: 53.92%



Conclusión: el federado de pesos iguales fue la mejor opción para el Banco 3





CONCLUSIONES

1

Alta efectividad

Se logró alto recall con bajo ratio de falsos positivos

2

Balance óptimo

Buen equilibrio entre detección, precisión y volumen de alertas

3

Valor de federación

La federación simulada aprovechó datos sin comprometer privacidad

4

Validación exitosa

La estrategia se validó con éxito en datos reales de Banco 3



La federación de datos permite **mejoras significativas** en la detección de fraude mientras **protege la privacidad** y es **escalable** entre instituciones

